

O andaime não paga

Quatro experimentos controlados sobre a contribuição dos componentes de operadores de variação agênticos em engenharia de dados.

Compute total
US\$ 1.304,06

Alvos
6 sadios · 27 mutantes no mais novo

Runs de experimento
132 · 553 passos de agente

Resultado principal
Negativo, e medido

Este relatório reporta um resultado majoritariamente negativo. Três experimentos e US\$ 976 não distinguiram nenhum componente do AVO do ruído da bancada; um quarto, de US\$ 82, achou 28,7 % no eixo que os três primeiros mantiveram fixo. A potência da bancada está declarada em cada seção e o preço da resposta que não foi comprada está calculado.

RESUMO

A NVIDIA descreve o AVO — *Agentic Variation Operators* — como uma busca evolutiva em que um coding agent é o operador de variação, formalizada como $\text{Vary}(P_t) = \text{Agent}(P_t, K, f)$. O sistema completo marcou 100 % no ARC-AGI-3. **Nenhuma comparação controlada da contribuição dos componentes do AVO foi publicada**, e o corpo do próprio post da NVIDIA afirma que seus números «não devem ser interpretados como medida direta da contribuição de performance do AVO».

Construímos uma bancada independente em engenharia de dados — seis alvos com função objetiva verificável — e rodamos essa comparação. **Em três experimentos e US\$ 976, remover a knowledge base, a memória entre passos ou o supervisor não produziu diferença distinguível do ruído, e trocar o AVO completo por um agente sem estrutura também não.** Um quarto experimento, de US\$ 82, mediu o eixo que os três primeiros mantiveram fixo — o modelo — e achou **28,7 % (IC 95 % [22,9 %, 33,4 %], $p = 0,016$)**. Dar $4,5 \times$ mais orçamento ao modelo menor comprou $-0,4 \%$ ($p = 0,90$).

Reportamos também dois defeitos de instrumento que só apareceram sob a disciplina de pré-registro, e o preço da resposta que não compramos: separar o efeito do supervisor do ruído exigiria $n \approx 41$ por braço, US\$ 1.889 e 119 h de relógio.

01 A pergunta

O AVO monta uma busca evolutiva sobre programas: um *incumbente* P_t , um agente que propõe variações consultando uma base de conhecimento K , e uma função objetiva f que arbitra. Em volta disso o harness acrescenta lineage versionado, um gate de correção, memória entre passos e um supervisor que detecta estagnação.

A pergunta desta reprodução é a mais simples possível e não estava respondida em lugar nenhum: **quanto cada uma dessas peças contribui?**

Um benchmark saturado não responde. Quando o ARC-AGI-3 lançou, humanos marcavam 100 % e IA de fronteira 0,51 %; até o fim de agosto de 2026 **três harnesses independentes** — Tycho, VISTA e AVO — já tinham chegado ao score perfeito no public set. Reproduzir 100 % ali é entrar num clube de três, não medir o que fez o trabalho.

02 A bancada

Seis alvos de engenharia de dados. Cada um é um quarteto: um *seed* correto e obviamente subótimo, uma função f que emite um score, uma knowledge base que descreve o domínio mas nunca a solução, e datasets determinísticos com hash fixado. A métrica primária é $\text{primary_final} / \text{primary_seed}$ — quanto o artefato final melhorou sobre o ponto de partida do próprio run.

O que impede a bancada de medir a coisa errada

Um candidato que memoiza a saída devolve o resultado certo instantaneamente e *passa em qualquer gate de correção*. Medido no alvo `etl_agg` antes das defesas: **4.672.896 ×** contra 4,16 × do seed. Sem três camadas anti-memoização, qualquer ablação mediria cache em vez de arquitetura. Cada `eval.py` carrega ao menos cinco mutantes semânticos — atalhos plausíveis que um otimizador tentaria — e o alvo só entra no experimento com todos rejeitados.

6 alvos sadios	132 runs	553 passos de agente	159 testes verdes	0 trapaças aceitas
-------------------	-------------	-------------------------	----------------------	-----------------------

03 O que o loop entrega

Antes de perguntar se a arquitetura importa, vale registrar que o loop funciona. Em 51 runs de ablação, **nenhum ficou abaixo de 4,22 ×**, e o gate segurou: 24 % dos passos foram rejeitados e em nenhum deles um candidato pior substituiu o incumbente.

EXPERIMENTO	ALVO	N	MELHORIA SOBRE O SEED
Ablação 1	<code>sql_agg</code>	20	5,06 ×
Fase 2A	<code>sql_agg</code>	11	4,95 ×
Ablação 2	<code>sql_workload</code>	20	7,38 ×

ACHADO 1 · POSITIVO

Um agente com incumbente, função objetiva e gate melhora artefatos de engenharia de dados em **4–7 ×** de forma repetível, sem reward hacking. Isso é o loop — não a arquitetura específica do AVO.

04 Os quatro contrastes

Cada experimento comparou braços que diferem em *uma* coisa, com o mesmo modelo, o mesmo `f` e o mesmo número de passos. A análise foi fixada antes do primeiro dado: bootstrap de 10.000 reamostragens para o intervalo, permutação para o p, Holm-Bonferroni sobre as comparações múltiplas.




FIG. 1 Efeito de cada manipulação, em porcentagem do braço de referência, com intervalo de 95 % por bootstrap. **Oito dos nove intervalos cruzam o zero.** O único que não cruza é a troca de modelo — e o contraste de orçamento, logo abaixo dele, cruza. Marcas em cinza: não distinguível do ruído. Em azul: distinguível.

ACHADO 2 · NULO

Nenhum componente do AVO — KB, memória, supervisor — nem a arquitetura inteira contra um agente sem estrutura, produziu diferença distinguível do ruído. **Três experimentos, US\$ 976.** Na Ablação 1 os braços mutilados pontuaram *acima* do completo.

05 O eixo que os três primeiros mantiveram fixo

Ao auditar a bancada percebemos que **todos os runs dos três primeiros experimentos rodaram um único modelo, `claude-opus-5`**. O runner não repassava `--model` e o harness usava o default dele. O eixo não estava ausente — estava invisível.

Um piloto de US\$ 16,60 mediu 27,5 % de diferença entre Opus e Sonnet, mas igualando por *passos*: pelos mesmos oito passos o Opus gastou 4,6 × mais dinheiro. O experimento decisivo igualou por **dólar** — 36 passos de Sonnet contra 8 de Opus, os mesmos US\$ 25,18 por run.




FIG. 2 Com orçamento igualado por dólar, o Sonnet fica 28,7 % abaixo do Opus. Quadruplicar seu orçamento em passos não move o resultado — 4,74 → 4,72. Barras de erro: ± 1 desvio. Valores da re-medição pareada (§ 07).

ACHADO 3 · POSITIVO

A diferença entre modelos é **capacidade, não orçamento**. Com o mesmo dólar, o Opus entrega +28,7 % (IC 95 % [22,9 %, 33,4 %], $p = 0,016$); dar 4,5 × mais orçamento ao Sonnet entrega -0,4 % (IC 95 % [-3,6 %, +3,6 %], $p = 0,90$). **US\$ 82 mediram isso; US\$ 976 medindo andaime não acharam nada.**

O alvo não esgotou

Um platô do Sonnet poderia significar que 36 passos exaurem o alvo. Pré-registramos esse risco e ele não se materializou: em duas das três sementes o Sonnet parou de achar melhorias com um a dois terços do orçamento por gastar (último aceite nos passos 12, 19 e 30 de 36). E a refutação decisiva dispensa isso — **o Opus alcança 6,62 × no mesmo alvo**, então existe headroom bem acima dos 4,72 × onde o Sonnet estaciona.




FIG. 3 A forma da busca. O Sonnet estabiliza a partir do passo ~12 e os 24 passos seguintes não movem nada; o Opus ainda subia no passo 8. **Os níveis não são comparáveis entre braços nesta figura** — a razão medida dentro do run carrega a deriva descrita em § 07. Os níveis corrigidos estão na Fig. 2; aqui o que importa é o formato.

06 O preço da resposta que não compramos

«Não distinguível» não é «não existe». A resolução desta bancada é de ~5,5 % no melhor experimento. Andaime que valha menos que isso é invisível aqui, e nada no que medimos exclui essa possibilidade.

O que podemos fazer é dizer quanto custaria enxergar. Para o contraste mais promissor entre os nulos — o supervisor, $\Delta = -0,396$ com desvio combinado 0,636 — a fórmula $n \approx 2 \cdot (2,8 \cdot s / \Delta)^2$ dá **n ≈ 41 por braço**: US\$ 1.889 e ~119 h para *um* par de braços.

E não há poder barato. Com os dados na mão testamos duas formas de reduzir a variância, e as duas falharam: parear por índice de semente (correlação média entre braços $r = +0,14$; chega a piorar a variância da diferença em 39 % num braço) e fixar o denominador da razão (piora em três dos quatro braços — a razão com denominador próprio já cancela a deriva dentro do run).

EXPERIMENTO	MEDIU	US\$	RELÓGIO	ACHOU
Ablação 1	componentes	210	15,0 h	nada
Fase 2A	AVO × agente simples	291	31,9 h	nada
Ablação 2	componentes	475	29,0 h	nada
Eixo do modelo	Opus × Sonnet, mesmo US\$	82	10,3 h	+28,7 %

07 Dois defeitos de instrumento

Um defeito de instrumento é um erro na bancada que faz o experimento medir outra coisa que não a que diz medir. Achar um vale mais que um resultado. O repositório cataloga 18; dois apareceram nesta rodada e ambos teriam mudado o que reportamos.

Defeito 17 — o detector de sessão cega errava nos dois sentidos

Uma sessão que escreve código sem nunca medir não testa o que o desenho diz testar. O portão que detectava isso decidia por substring, e errava em ambas as direções. Contado sobre 300 transcrições: **1.293 comandos casavam como «tentou medir», dos quais 254 eram `cat`, 227 `sed` e 126 `grep`** — ler o fonte do avaliador contava como medir. Na outra ponta, um agente que canaliza a saída para um parser ou importa `medir()` para comparação pareada não emitia as strings procuradas: **757 comandos com saída de medição não eram reconhecidos**. O detector marcava como cega exatamente a sessão que mede melhor. Falsos positivos após o conserto: $7 \rightarrow 1$, com o controle negativo ainda reprovando 6 de 6.

Defeito 18 — o denominador da métrica deriva por bloco de execução

A métrica é `primary_final / primary_seed`, e o denominador é medido uma vez, no início do run, sobre um artefato de seed **idêntico** em todos eles. Ao longo dos 11 runs do eixo do modelo ele variou **1,68 ×**.




FIG. 4 O mesmo artefato de seed, medido dentro de cada run (esquerda) e re-medido em sequência imediata com a máquina ociosa (direita). A dispersão de $1,68 \times$ colapsa para $1,17 \times$. Não é ruído branco: é deriva por *bloco* de execução.

A nuance é o que importa. Numa ablação de braços **intercalados**, o ruído do seed é comum a todos e a razão o cancela — testamos, e fixar o denominador *piorava* o cv em três dos quatro braços. Entre **experimentos** de dias e durações diferentes não há nada em comum para cancelar, e a razão passa a medir o estado da máquina. Comparação entre experimentos exige re-medição pareada; custa quatro minutos e sem ela o resultado da seção 05 não seria legível.

08 Limitações

Esta seção é a mais importante do relatório, porque o resultado principal é negativo.

- **Potência.** $n = 3-11$ por braço; a diferença mínima detectável fica entre 5,5 % e 30 % conforme o experimento. Efeitos menores existem e seriam invisíveis aqui.
- **Orçamento igualado por passos, não por tokens**, nos três experimentos de andaime. Isso favorece sistematicamente o braço com supervisor, que gasta mais por passo — ou seja, inclina o desenho *a favor* do AVO completo, e mesmo assim o efeito não apareceu.
- **Um componente não foi ablacionado.** O `no_lineage` exigiria um invólucro que não existe no runner; fica declarado como ausente, não como feito.
- **Domínio estreito.** Otimização com `f` objetiva e verificável. Onde não se consegue escrever `f`, nada disto foi testado — e é justamente a classe de problema em que a pergunta sobre generalidade é interessante.
- **Dois modelos no total.** A escala não está fechada.
- **O seed já funciona.** Nossos alvos partem de código correto e lento. Onde o modelo sozinho vai mal — como no ARC-AGI-3, com 0,51 % de baseline — o andaime plausivelmente tem muito mais espaço para aparecer. *Isso é hipótese, não algo que medimos.*

09 Disciplina

Três decisões foram tomadas contra o interesse de quem as tomou, e estão registradas com data:

- O **adendo ao pré-registro** foi escrito com 12 dos 20 runs prontos e nenhuma estatística rodada. Custou a exclusão de duas sementes do braço de referência e foi registrado antes de se saber que não mudaria a conclusão — não mudou.
- O **detector de cegueira não foi consertado durante o experimento**, embora a evidência do conserto já estivesse na mão. Alterar um instrumento logo depois de ele reprovar runs do próprio braço de referência é o movimento que a disciplina existe para impedir, mesmo estando certo.
- A hipótese «*o braço completo é mais consistente*» (cv 4,4 % contra 6,9 / 12,0 / 15,9 %) foi testada por permutação antes de virar frase — **p entre 0,38 e 0,60, não se sustenta** — e está registrada como testada e descartada.

10 Conclusão

O loop evolutivo com função objetiva entrega $4-7 \times$ de forma repetível e sem trapaça. Isso é real e é o que vale adotar: **um incumbente, um número para maximizar, e um gate que você tentou quebrar de propósito.**

A arquitetura em volta dele — knowledge base, memória entre passos, supervisor de estagnação, e o conjunto contra um agente sem estrutura — **não se distinguiu do ruído em três experimentos independentes e US\$ 976.** Não provamos que essas peças são inúteis; provamos que, ao preço que esta bancada consegue pagar, elas não aparecem. E dissemos quanto custaria enxergar.

O eixo que os três primeiros experimentos mantiveram fixo — o modelo — foi o que moveu o resultado: **+28,7 % com o mesmo dólar**, e orçamento extra no modelo menor não compra a diferença. Para quem decide onde investir esforço de engenharia, essa é a frase operacional do trabalho: **meça se o andaime paga antes de construí-lo, e considere que trocar o modelo pode ser o experimento mais barato que você tem.**

11 Reprodutibilidade

Dados brutos, pré-registros com os desvios declarados, os 18 defeitos de instrumento e os scripts de análise estão no repositório. Todos os números deste relatório saem de `results.jsonl` e `remedido_modelo.jsonl` e reproduzem com os comandos documentados em cada relatório. Harness da busca: `gatordevin/avo`, fixado por commit em `vendor/avo.lock`. O que é da NVIDIA e o que é escolha desta reprodução está separado linha a linha em `docs/AVO_REPLICATION_REPORT.md`. Relatórios longos por experimento: `experiments/ABLACA0_RESULTADO.md`, `experiments/EIX0_MODELO_RESULTADO.md`, `experiments/DEFEITOS.md`.